


Report Tensorflow Playground: Spiral X^1 , X^2



O que foi feito.

Arquitetura: 3 Layers × 8 Neurônios

O spiral é geometricamente complexo mas regular — suas fronteiras são curvas que seguem um padrão previsível. 3 hidden layers fornecem profundidade suficiente para capturar essa hierarquia sem incorrer nos custos de redes mais profundas: vanishing gradient nas primeiras camadas, overfitting por excesso de parâmetros, e maior custo computacional por época. 8 neurônios por layer equilibram capacidade de representação com simplicidade.

Ativação: Tanh

Com apenas X_1 e X_2 como features, o modelo precisa aprender fronteiras suaves que acompanham a geometria espiral. Tanh produz saídas contínuas entre -1 e 1, gerando fronteiras igualmente suaves e compatíveis com essa geometria. ReLU, por ser linear por partes, exigiria muito mais neurônios para aproximar as mesmas curvas com segmentos retos. A centralização em zero do Tanh também favorece o fluxo de gradientes durante o backpropagation — visível na imagem pela alternância equilibrada de pesos azuis e laranja na rede.

Learning Rate: 0.03 → 0.01 (Scheduling)

A estratégia de scheduling foi aplicada em duas fases: $lr=0.03$ nas primeiras 2.000 épocas para convergir rapidamente à região do mínimo, reduzindo para $lr=0.01$ nas 2.466 épocas restantes para o ajuste fino da fronteira. Essa transição é justamente o que permite o resultado observado — a lr maior acelera a descida inicial no espaço de parâmetros sem precisão, enquanto a lr menor evita que o modelo "salte" o mínimo nas épocas finais, onde a separação dos braços da espiral exige ajustes graduais. O resultado de training loss 0.014 reflete essa precisão na convergência final.

Regularização: L2 — 0.001

L1 foi descartado pois tenderia a zerar pesos associados a X_1 ou X_2 — ambas indispensáveis para aprender a geometria espiral. L2 com $\lambda=0.001$ mantém todos os pesos ativos mas pequenos e distribuídos, o que se reflete na fronteira suave do output: sem regiões de decisão erráticas ou excessivamente rígidas. O gap entre test loss (0.032) e training loss (0.014) indica

leve overfitting, mas dentro de um nível aceitável — λ mais alto aumentaria o gap pelo lado oposto, causando underfitting.

Resultado

A fronteira de decisão separa os dois braços da espiral de forma limpa e contínua, com test loss de 0.032 — confirmando que a configuração generaliza bem para dados não vistos e não apenas memorizou o treino.